

Design en implementatie van een in-house MDM-oplossing in Microsoft Fabric als benchmark tegenover Profisee in een multi-ERP-omgeving.

Alvaro Van Damme.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Mevr. Karine Van Driessche

Co-promotor: Dhr. Gert-Jan Dugardein

Academiejaar: 2025–2026

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Woord vooraf

Met het schrijven van dit voorwoord leg ik de laatste hand aan mijn bachelorproef, het sluitstuk van mijn opleiding Toegepaste Informatica aan HoGent.

Toen ik aan het traject van AI & Data begon, wist ik zeker: ik wilde een onderwerp uitdiepen waarin data centraal stond. Het idee om orde te scheppen in de chaos van complexe en gefragmenteerde bedrijfsdata heeft me altijd gefascineerd. De uitdaging om voor IPCOM een Proof of Concept te bouwen voor een in-house Master Data Management-oplossing binnen Microsoft Fabric, bleek na een tijdje een onderwerp voor mij waar ik echt interesse in had. Het bleek een boeiende technische puzzel waarbij ik niet alleen diep in PySpark, data matching en lakehouse-architecturen mocht duiken, maar ook leerde hoe deze theorieën zich vertalen naar de realiteit van een grote onderneming.

Natuurlijk is deze bachelorproef niet uitsluitend het resultaat van mijn eigen inspanningen. Ik wil dan ook graag de tijd nemen om een aantal mensen te bedanken die een cruciale rol hebben gespeeld in de totstandkoming van dit werk.

In de eerste plaats wil ik mijn stagebedrijf, IPCOM, bedanken voor de mogelijkheid tot het uitbouwen van deze oplossing en het vertrouwen. Een speciale dankjewel aan mijn co-promotor, Gert-Jan Dugardein, voor de expertise en begeleiding binnen een voor mij eerst onbekende wereld en de verhelderende brainstormsessies. Bedankt voor het geduld en de inzichten, zelfs wanneer ik een bepaald concept niet direct snapte en het paar keer opnieuw moest vragen.

Daarnaast wil ik mijn academische promotor, Karine Van Driessche, oprecht bedanken. Uw kritische blik voor het schrijven van een bachelorproef, de constructieve feedback en de gerichte bijsturingen hebben ervoor gezorgd dat dit onderzoek vooral academisch op punt staat.

Ik wens u veel leesplezier.

Alvaro Van Damme
Wetteren, 4 mei 2026

Samenvatting

In de huidige datagedreven bedrijfswereld is een accuraat en uniform overzicht van bedrijfsdata cruciaal. IPCOM, een internationale groep actief in technische isolatie, kampt met gefragmenteerde en inconsistente data die verspreid is over diverse lokale Enterprise Resource Planning (ERP)-systemen. Het gebrek aan een centrale *single source of truth* voor artikel- en leveranciersdata bemoeilijkt niet alleen de overkoepelende rapportage, maar ook de strategische besluitvorming.

Commerciële Master Data Management (MDM)-platformen, zoals Profisee, bieden hiervoor een oplossing. Deze pakketten brengen echter aanzienlijke licentiekosten en architecturale complexiteit met zich mee, voornamelijk omdat bedrijfsdata veelal naar een extern systeem verplaatst moet worden. Dit onderzoek vertrekt daarom vanuit de volgende onderzoeksvraag: *In hoeverre kan een in-house MDM-oplossing, gebouwd binnen de Microsoft Fabric-omgeving, een accuraat en schaalbaar alternatief bieden voor gespecialiseerde commerciële MDM-pakketten?*

Om deze vraag te beantwoorden, is een Proof of Concept (PoC) ontwikkeld volgens de medallion-architectuur binnen Microsoft Fabric. De dataset besloeg ruim 150.000 ruwe artikelrecords, afkomstig van IPCOM-entiteiten uit Oostenrijk, Zwitserland en Noorwegen. Na extractie is de data eerst gestandaardiseerd naar een *canonical model*. Vervolgens zijn de records ontdebeld middels een combinatie van deterministische matching (harde regels) en probabilistische fuzzy matching (op basis van de Levenshtein-afstand) via PySpark. Tot slot zijn via specifieke *survivorship rules* geconsolideerde *golden records* gegenereerd zonder dataverlies voor de lokale entiteiten.

De resultaten tonen aan dat de in-house ontwikkelde Fabric-oplossing zeer competitief is. Het systeem realiseerde een algehele deduplicatiegraad van 33,4%, wat nagenoeg gelijkwaardig is aan de benchmark van 35,1% behaald door het commerciële Profisee-platform. De deterministische regels identificeerden met succes de meerderheid van de duplicaten, terwijl de fuzzy matching cruciaal bleek om de complexere, lokaal afwijkende records te koppelen.

Uit het onderzoek wordt geconcludeerd dat Microsoft Fabric een krachtig, naadloos integreerbaar en rendabel alternatief vormt voor externe MDM-systemen. De voornaamste beperking van de huidige PoC is het ontbreken van een grafische *low-code* interface voor niet-technische *data stewards*. Daarom beveelt dit onderzoek verdere integratie met tools zoals Power Apps aan als beheerlaag, evenals het onderzoeken van automatische vertaalservices om taalkundige barrières tijdens het matchen in de toekomst nog effectiever te overbruggen.

Inhoudsopgave

Lijst van tabellen	vii
1 Inleiding	1
1.0.1 Deelvragen m.b.t probleemdomrein	2
1.0.2 Deelvragen m.b.t oplossingsdomein	2
1.1 Opzet van deze bachelorproef	2
2 Stand van zaken	4
2.0.1 Master Data Management.	4
2.0.2 Golden records en dataconsolidatie	5
2.0.3 Multi-ERP-omgevingen en de rol van Master Data Management 6	
2.0.4 Data quality en data governance binnen MDM	7
2.0.5 Bestaande MDM-oplossingen en implementatiebenaderingen .	7
2.0.6 Open uitdagingen en positionering van dit onderzoek.	8
3 Methodologie	9
3.1 Methodologie	9
3.1.1 Onderzoeksopzet.	9
3.1.2 Onderzoekstechnieken.	9
3.1.3 Dataverzameling en requirements	10
3.1.4 Technische uitvoering van de PoC.	10
3.1.5 Evaluatiecriteria.	11
3.1.6 Tools en technologie (initiële keuze)	11
3.1.7 Planning (14 weken, wekelijkse cyclus).	11
4 Ontwerp en Implementatie PoC	13
4.1 Systeemarchitectuur in Microsoft Fabric.	13
4.2 Fase 1: Data Ingestion en Landing	14
4.3 Fase 2: Harmonisatie en Canonical Model	14
4.4 Fase 3: Data Matching Strategieën	15
4.4.1 Deterministische Matching (Hard Rules)	15
4.4.2 Fuzzy/AI-gebaseerde Matching (Experimenteel)	15
4.5 Fase 4: Survivorship Rules en Golden Record Creatie	16
4.6 Fase 5: Opslag en Publicatie.	17

5	Resultaten en Evaluatie	18
5.1	Datakwaliteit en Harmonisatie	18
5.2	Evaluatie van de Matching Strategieën	18
5.2.1	Resultaten Deterministische Matching	19
5.2.2	Resultaten Fuzzy Matching	19
5.3	Validatie van de Golden Records	19
5.4	Systeemprestaties en Performantie	20
5.5	Benchmark: Microsoft Fabric versus Profisee	20
5.6	Conclusie van de Resultaten	20
6	Conclusie	22
A	Onderzoeksvoorstel	24
A.1	Inleiding	24
A.1.1	Deelvragen m.b.t probleemdomrein	25
A.1.2	Deelvragen m.b.t oplossingsdomein	25
A.2	Stand van zaken	26
A.2.1	Master Data Management	26
A.2.2	Golden records en dataconsolidatie	27
A.2.3	Multi-ERP-omgevingen en de rol van Master Data Management 27	
A.2.4	Data quality en data governance binnen MDM	28
A.2.5	Bestaande MDM-oplossingen en implementatiebenaderingen	29
A.2.6	Open uitdagingen en positionering van dit onderzoek	29
A.3	Methodologie	30
A.3.1	Onderzoeksopzet	30
A.3.2	Onderzoekstechnieken	30
A.3.3	Dataverzameling en requirements	31
A.3.4	Technische uitvoering van de PoC	31
A.3.5	Evaluatiecriteria	31
A.3.6	Tools en technologie (initiële keuze)	32
A.3.7	Planning (14 weken, wekelijkse cyclus)	32
A.4	Verwacht resultaat, conclusie	32
A.4.1	Verwachte resultaten	32
A.4.2	Verwachte visualisaties en metingen	32
A.4.3	Meerwaarde voor de doelgroep	33
A.4.4	Verwachte conclusie	33
	Bibliografie	35

Lijst van tabellen

3.1	Planning en deliverables (14 vrijdagen)	12
5.1	Vergelijkende benchmark tussen de Fabric PoC en Profisee.	21
A.1	Planning en deliverables (14 vrijdagen)	34

1

Inleiding

Deze bachelorproef onderzoekt Master Data Management (MDM), multi-ERP-omgevingen en het concept van "golden records". Specifiek richt het onderzoek zich op de casus van IPCOM, een bedrijf in de isolatiesector dat met meerdere ERP-systemen werkt. IPCOM heeft op dit moment het probleem dat verschillende entiteiten binnen de groep (zoals de entiteiten in Oostenrijk, Zwitserland en Noorwegen) dezelfde artikelen van dezelfde leveranciers kopen, maar dat deze door de verschillende bronssystemen niet eenvoudig te identificeren zijn als hetzelfde product. Hierdoor ontstaan inconsistenties in artikel- en leveranciersdata, wat een directe impact heeft op rapportering en besluitvorming.

Om dit probleem aan te pakken is IPCOM momenteel een pilot gestart met de commerciële MDM-tool Profisee. Deze bachelorproef zal een proof-of-concept zijn voor een in-house gebouwde oplossing voor het probleem wat IPCOM heeft. Het fundament van de oplossing zal steunen op deterministische matching regels en machine learning, of fuzzy-matching ondersteuning waar nodig. De gelijktijdige opstart van beide oplossingen roepen een interessante vraag op. Hoe presteert een in vergelijking kleinschalige maar in-house gebouwde oplossing tegenover een veel grotere maar externe out-of-the-box oplossing, wanneer exact dezelfde inputdata en mappings worden gebruikt?

De belangrijkste doelgroep wordt gevormd door data-engineers en business-gebruikers binnen de organisatie die werken met deze data in het datawarehouse en het rapportageplatform (bijvoorbeeld Power BI). Zij ondervinden dagelijks hinder van gefragmenteerde data en hebben nood aan een gecentraliseerde, betrouwbare bron van waarheid, namelijk een "golden record" per artikel en leverancier, die de data-kwaliteit structureel verbetert.

De centrale onderzoeksvraag luidt als volgt: Hoe kan een in-house Master Data Management-oplossing in Microsoft Fabric worden ontworpen en geïmplementeerd voor artikel- en leveranciersdata, zodat deze kan dienen als objectieve ben-

chmark tegenover een commerciële MDM-tool (Profisee) binnen een multi-ERP-omgeving? De doelstelling van deze bachelorproef is eenduidig: een PoC bouwen voor een MDM-tool in Microsoft Fabric, specifiek gericht op de ERP-data van Oostenrijk, Zwitserland en Noorwegen. Op basis van de vergelijking tussen deze PoC en de Profisee-pilot kunnen concrete aanbevelingen worden geformuleerd over de toegevoegde waarde van commerciële pakketten versus in-house oplossingen voor data harmonisatie en matching.

1.0.1. Deelvragen m.b.t probleemdomein

- Hoeveel duplicaten en conflicterende records komen voor over de geselecteerde ERP-systemen heen?
- Welke datakwaliteitsproblemen treden het meest op bij de geselecteerde artikel- en leveranciersdata (bijvoorbeeld het hoge percentage ontbrekende waarden)?
- Welke identificatievelden (zoals EAN en artikelnaam) zijn bruikbaar in de systemen om een correcte mapping op te zetten?
- Hoe vaak verandert een golden record de oorspronkelijke data bij welk specifiek bronsysteem?

1.0.2. Deelvragen m.b.t oplossingsdomein

- Hoe presteert de in-house Fabric PoC ten opzichte van de commerciële Profisee-setup wanneer dezelfde mappings en rulesets worden gebruikt?
- Welke matching-technieken (deterministisch op basis van EAN versus fuzzy matching of AI op artikelnaam) leveren de hoogste nauwkeurigheid?
- Welke consolidatieregels (survivorship-logica) zorgen voor de meest consistente "golden records"?
- Hoe kan de publicatie van golden records worden ingericht zodat lokale id's correct verwijzen naar de golden records en alle entiteiten hiervan profiteren?
- Hoeveel verbetering in datakwaliteit wordt gerealiseerd en visueel meetbaar gemaakt na implementatie van de MDM-oplossing?

1.1. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In het volgende hoofdstuk 2, de literatuurstudie wordt een overzicht gegeven van de theoretische kaders rond Master Data Management, golden records en datakwaliteit binnen een multi-ERP-context.

Daarna wordt de methodologie 3 toegelicht voor het ontwikkelen van een proof-of-concept in Microsoft Fabric, waarbij artikel- en leveranciersdata uit drie ERP-systemen worden geharmoniseerd

En als laatst 6 worden de resultaten van de proof-of-concept geëvalueerd en afgezet tegen een commerciële benchmark om een onderbouwd "build vs. buy"-advies te formuleren.

2

Stand van zaken

In dit hoofdstuk bespreken we de theoretische kernconcepten die van toepassing zijn op deze bachelorproef, het begrip van zaken zoals master data management (MDM) en data kwaliteit (binnen een Multi-ERP omgeving) zijn nodig om de probleemstelling en de noodzaak in dergelijke situaties te begrijpen en om alsook de kwaliteit en voorwaarden van een mogelijke oplossing te kunnen inzien.

2.0.1. Master Data Management

Master Data Management (MDM) wordt omschreven als een methode om master data te onderhouden, te integreren en te harmoniseren, met als doel consistente informatievoorziening over informatiesystemen heen te ondersteunen (Hikmawati e.a., [2021](#)). Master data verwijst daarbij naar kerngegevens die organisatiebreed worden hergebruikt en die verschillende processen en afdelingen met elkaar verbinden. Vilminko-Heikkinen en Pekkola positioneren MDM hierbij als een organisatiebrede data-managementpraktijk die expliciet gericht is op het verbeteren van de kwaliteit van deze kerngegevens (Vilminko-Heikkinen & Pekkola, [2019](#)).

De kernfunctie van MDM is het beheersen van master data zodat deze consistent, accuraat, actueel en relevant blijft over applicaties en organisatie-eenheden heen (Hikmawati e.a., [2021](#)). Wanneer dit beheer tekortschiet, neemt het risico op onnauwkeurige of tegenstrijdige gegevens toe, wat de betrouwbaarheid van rapportering en besluitvorming ondermijnt (Hikmawati e.a., [2021](#)). Zeker wanneer gegevens verspreid zijn over meerdere systemen, kunnen definities en formaten verschillen, waardoor fragmentatie ontstaat (Vilminko-Heikkinen & Pekkola, [2019](#)). Dit maakt MDM naast een technisch ook een organisatorisch vraagstuk: meerdere teams beheren immers dezelfde kernentiteiten.

Vilminko-Heikkinen en Pekkola benaderen MDM niet als louter softwaretool, maar als een praktijk die aanpassingen in processen en werkwijzen vereist (Vilminko-Heikkinen & Pekkola, [2019](#)). Het omvat beleid en infrastructuur om master data

te capteren en te delen, met focus op consistentie en tijdigheid. Dit impliceert dat een MDM-initiatief onlosmakelijk verbonden is met *data governance*: het vastleggen van afspraken en controlemechanismen (Hikmawati e.a., 2021). Uit onderzoek van Hikmawati blijkt dan ook dat MDM-initiatieven vaak leiden tot een hertekening van rollen om datakwaliteit structureel te borgen.

Governance uit zich concreet in rollen en verantwoordelijkheden. In een MDM-context zijn rollen zoals *data owner* (eindverantwoordelijkheid) en *data steward* (operationele bewaking) essentieel om eigenaarschap te organiseren (Hikmawati e.a., 2021). Deze verdeling maakt het mogelijk kwaliteitsproblemen toe te wijzen en op te volgen (Vilminko-Heikkinen & Pekkola, 2019). Zonder expliciet eigenaarschap blijft het risico bestaan dat master data opnieuw divergeert, zelfs bij aanwezigheid van een technisch MDM-platform (Vilminko-Heikkinen & Pekkola, 2019).

Voor IPCOM is dit relevant omdat product- en leveranciersgegevens uit meerdere ERP-systemen samenkomen. MDM kan bijdragen aan harmonisatie door definities en kwaliteitsregels vast te leggen (Hikmawati e.a., 2021). Echter, zoals de literatuur benadrukt, hangt succes af van organisatorische verankering. Binnen deze bachelorproef wordt MDM daarom onderzocht als methode om duplicatie te reduceren, mits de implementatie zowel technisch als organisatorisch wordt gedragen (Hikmawati e.a., 2021).

2.0.2. Golden records en dataconsolidatie

De multi-ERP-context van IPCOM impliceert dat master data verspreid is, waardoor informatie over één entiteit gefragmenteerd voorkomt (Elahi, 2024). Elahi koppelt dit aan een hogere werkdruk, omdat gebruikers meerdere bronnen moeten consolideren. Een manuele aanpak vergroot bovendien het risico op fouten; een risico dat toeneemt naarmate het aantal bronsystemen groeit (Elahi, 2024).

Een centraal concept om dit op te lossen is het *golden record*: de enkelvoudige weergave die ontstaat nadat duplicaten zijn samengebracht en relevante informatie is behouden (Elahi, 2024). Bij IPCOM kan dit gaan om een product waarvan attributen (zoals leveranciersnummer, prijs, of omschrijving) in verschillende systemen bestaan. Het golden record brengt per attribuut de geselecteerde waarde samen tot één consistente representatie voor analyse en rapportering (Elahi, 2024).

Elahi onderscheidt drie stappen die hieraan voorafgaan. *Data matching* groepeer records op basis van waarschijnlijkheid. Vervolgens kan *deduplicatie* of *data merging* de datasets combineren. De brug naar het golden record wordt gevormd door *data survivorship*: het selecteren van de beste attributen uit duplicaten om één uniforme record te vormen (Elahi, 2024).

Er zijn meerdere benaderingen voor survivorship mogelijk, afhankelijk van datakwaliteit (Elahi, 2024):

- **Manuele selectie:** Het meest volledige record kiezen (moeilijk schaalbaar).

- **Bronprioriteit:** Selectie op basis van de betrouwbaarheid van het bronsysteem.
- **Attribuutlogica:** Per veld de beste waarde kiezen (bijv. meest recente update).
- **Samengesteld (composite):** Waarden conditioneel overschrijven om informatie uit meerdere bronnen te combineren.

De operationalisering gebeurt via *survivorship rules* (bijv. 'langste waarde wint' of 'laatste update wint'). Elahi benadrukt dat deze regels iteratief moeten worden bijgestuurd op basis van de uitkomst (Elahi, 2024). In dit onderzoek wordt geëvalueerd welke regels passen bij de datakwaliteit van IPCOM: volstaat bronprioriteit, of is een complexe, attribuutgebaseerde benadering noodzakelijk?

2.0.3. Multi-ERP-omgevingen en de rol van Master Data Management

In organisaties met een *multi-ERP-landschap* zijn master data en processen verdeeld. Maedche (2010) beschrijft dat integratie in grote ondernemingen lastig blijft wanneer het aantal en de diversiteit van ERP-systemen toeneemt. Hierdoor ontstaat een masterdata-probleem: dezelfde entiteiten bestaan in meerdere systemen met afwijkende definities (Maedche, 2010).

MDM verschilt hierin fundamenteel van ERP. Waar ERP procesgericht is, beoogt MDM een *enterprise-wide single version of the truth* die onafhankelijk is van specifieke applicaties (Maedche, 2010). Omdat ERP en MDM elkaar functioneel kunnen overlappen, verschuift het ontwerpprobleem naar de complementariteit tussen beide in een complex landschap.

De uitdagingen zijn vooral zichtbaar in *operationele* MDM-scenario's. Standalone MDM-oplossingen kunnen integratieproblemen veroorzaken rond distributie en semantische mapping (Maedche, 2010). Dit wijst erop dat multi-ERP-omgevingen niet alleen consolidatie vereisen, maar ook een integratieaanpak die synchronisatie beheersbaar maakt.

Maedche onderscheidt in deze context twee scenario's:

1. *Collaboration in corporate groups:* Een stertopologie met centraal beheer en lokale restricties.
2. *Heterogeneous system landscapes:* Een mesh-topologie zonder duidelijke 'master', waarbij consolidatie vooral dient voor rapportering (Maedche, 2010).

Om MDM te laten aansluiten stelt Maedche een ERP-centrische benadering voor via *shared MDM capabilities*. Dit omvat een MDM-hub, integratiemiddleware en een ingebedde MDM-component in de ERP-systemen. Het doel is dat wijzigingen consistent en semantisch correct worden doorgegeven (Maedche, 2010).

Voor IPCOM betekent dit dat de keuze voor een integratiepatroon cruciaal is. Afhankelijk van de behoefte aan lokale autonomie kan een hybride benadering worden

onderzocht, waarbij centrale standaarden worden gecombineerd met lokale verrijking (Maedche, 2010).

2.0.4. Data quality en data governance binnen MDM

Datakwaliteit is zowel een drijfveer als een evaluatiecriterium voor MDM. Kwaliteit wordt hierbij gezien als geschiktheid voor gebruik, gemeten via dimensies zoals accuraatheid, volledigheid, consistentie en tijdigheid (Hikmawati e.a., 2021). Problemen zoals duplicaten of ontbrekende waarden beïnvloeden direct de besluitvorming (Hikmawati e.a., 2021).

MDM beoogt deze problemen te reduceren, maar Vilminko-Heikkinen en Pekkola benadrukken dat datakwaliteit geen louter technisch resultaat is; het vereist een combinatie van processen en technologie (Vilminko-Heikkinen & Pekkola, 2019). Dit veronderstelt duidelijke afspraken over datacreatie en validatie, verankerd in *data governance*.

Zonder heldere governance (rollen, eigenaarschap) wordt kwaliteitsborging bemoeilijkt (Vilminko-Heikkinen & Pekkola, 2019). Hikmawati bevestigt dat onduidelijk ownership en gebrek aan procedures de effectiviteit van MDM ondermijnen. Governance concretiseert wie beslissingsrecht heeft (data owner) en wie de kwaliteit bewaakt (data steward), vaak ondersteund door een *data governance council* (Hikmawati e.a., 2021).

Het proces start doorgaans met *data profiling* om problemen zichtbaar te maken, gevolgd door opschoning (cleaning) en synchronisatie. Deze stappen zijn pas effectief wanneer ze gekoppeld zijn aan meetbare kwaliteitsdoelen, zoals indicatoren voor de duplicatiegraad (Hikmawati e.a., 2021).

Voor IPCOM betekent dit dat de technische oplossing gepaard moet gaan met governance die lokale verantwoordelijkheid en centrale uniformiteit combineert. Door data ownership toe te wijzen, wordt datakwaliteit een bestuurbaar resultaat in plaats van een toevallige uitkomst (Vilminko-Heikkinen & Pekkola, 2019).

2.0.5. Bestaande MDM-oplossingen en implementatiebenaderingen

MDM-oplossingen variëren in architectuur, synchronisatiepatronen en governance-ondersteuning (Rengasamy, 2025). Vooral in multi-ERP-omgevingen is de keuze tussen centralisatie en federatie bepalend.

- **Gecentraliseerd:** Eén MDM-hub fungeert als de primaire bron.
- **Federated:** Eigenaarschap blijft bij businessfuncties, terwijl consistentie via afspraken wordt bewaakt. Dit is geschikt wanneer lokale autonomie zwaar weegt (Rengasamy, 2025).

Daarnaast onderscheidt de literatuur drie MDM-patronen (Rengasamy, 2025):

1. *Registry*: Focus op referenties en identifiers zonder dataverplaatsing.

2. *Coexistence*: Lokale opslag met synchronisatie naar een centrale standaard.
3. *Transaction Hub*: Real-time verwerking van updates als centrale autoriteit.

Voor multi-ERP-contexten worden vaak Coexistence of Transaction Hubs aangeraden, omdat bronsystemen operationeel moeten blijven (Maedche, 2010). Rengasamy (2025) adviseert een gefaseerde implementatie: starten met een afgebakend domein en iteratief uitbreiden. Dit sluit aan bij de visie dat datakwaliteit een continu proces is (Hikmawati e.a., 2021).

Voor IPCOM wordt een federated of coexistence-achtige benadering onderzocht. Dit maakt het mogelijk om centrale definities te combineren met operationele continuïteit in de ERP-systemen (Rengasamy, 2025).

2.0.6. Open uitdagingen en positionering van dit onderzoek

MDM-initiatieven kennen zowel technische als organisatorische uitdagingen (Pansara, 2021). Ten eerste is er **data governance**: zonder duidelijke rollen en procedures kunnen inconsistenties opnieuw in systemen sluipen (Pansara, 2021). De vraag is hoe governance consistentie kan afdwingen zonder lokale werking te blokkeren (Vilminko-Heikkinen & Pekkola, 2019).

Ten tweede vormt **data-integratie** een risico. Synchronisatieverschillen en semantische mismatches tussen MDM en ERP kunnen leiden tot fouten (Maedche, 2010). Ook bij het samenvoegen van records (survivorship) kan context verloren gaan (Pansara, 2021).

Ten derde vereisen **data-standaarden** afstemming tussen afdelingen, wat in gedecentraliseerde contexten moeilijk is.

Deze bachelorproef positioneert zich als toegepast onderzoek. MDM-concepten, matching-technieken en survivorship-strategieën worden vertaald naar een proof-of-concept voor de multi-ERP-casus van IPCOM. Het doel is om deze in-house oplossing in te zetten als een objectieve benchmark tegenover een commerciële MDM-pilot (Profisee). Hierbij wordt geëvalueerd hoe duplicatie effectief kan worden gereduceerd via deterministische en AI-gebaseerde matching, en of een in-house setup kwalitatief kan concurreren met een kant-en-klaar platform.

3

Methodologie

3.1. Methodologie

Dit hoofdstuk beschrijft de methodologische aanpak van dit toegepaste onderzoek. Er is gekozen voor een case study met als einddoel een technische PoC in Microsoft Fabric. In de volgende paragrafen worden achtereenvolgens de onderzoeksstrategie, de dataverzameling en de technische stappen van de pipeline toegelicht. Tot slot volgt een overzicht van de meetbare evaluatiecriteria voor de benchmark tegen de commerciële Profisee-pilot, afgesloten met de gekozen tools en de projectplanning.

3.1.1. Onderzoeksopzet

Deze bachelorproef is **toegepast onderzoek** binnen de bedrijfscontext van IPCOM en wordt uitgevoerd als **case study** met een **PoC** als technisch eindresultaat. De centrale onderzoeksvraag uit Sectie A.1 wordt beantwoord door (1) literatuurstudie, (2) requirements- en contextanalyse via directe afstemming met de interne data engineer, (3) ontwerp en implementatie van een PoC in Microsoft Fabric, waarbij de scope bewust beperkt wordt tot artikel- en leveranciersdata uit drie specifieke ERP-systemen (Oostenrijk, Zwitserland en Noorwegen). Tot slot volgt (4) een evaluatie waarbij deze in-house PoC fungeert als objectieve benchmark tegenover een lopende pilot met het commerciële MDM-platform Profisee.

3.1.2. Onderzoekstechnieken

De gebruikte onderzoekstechnieken zijn:

- **Literatuurstudie:** concepten, implementatiebenaderingen en open uitdagingen rond MDM, multi-ERP, golden records en datakwaliteit.
- **Expert-consultatie en documentanalyse:** directe afstemming met de co-promotor

(data engineer) als hoofd-stakeholder en het hergebruiken van reeds intern opgestelde rule-sets en datamappings.

- **Data-analyse en data profiling:** bepalen van een objectieve baseline (zoals het huidige percentage ontbrekende velden) op representatieve datasets uit de geselecteerde bronsystemen.
- **Ontwerp en implementatie PoC:** data harmonisatie, deterministische en AI-gestuurde matching, survivorship rules en golden record-opbouw in Microsoft Fabric.
- **Evaluatie (Benchmark):** kwantitatieve en kwalitatieve vergelijking van de Fabric PoC-output met zowel de originele baseline als de resultaten van de Profisee-oplossing.

3.1.3. Dataverzameling en requirements

Er is directe toegang verleend tot de benodigde databases. Dit versnelt de dataverzameling aanzienlijk. De scope is afgebakend tot entiteiten van het type *Article* en *Supplier*, aangezien deze de grootste kans op overlap vertonen over de verschillende entiteiten heen. Klantendata wordt buiten beschouwing gelaten vanwege het sterk lokale karakter.

Er worden geen brede stakeholder-interviews gehouden; de requirements, pijnpunten en reeds bestaande mappings (bijvoorbeeld vertalingen van landcodes en lokale veldnamen) worden rechtstreeks gecapteerd via de interne data engineer. Dit vormt de fundering voor het canonical model.

3.1.4. Technische uitvoering van de PoC

De PoC implementeert een reproduceerbare pipeline in Microsoft Fabric met de volgende stappen:

1. **Landing:** inladen van datasnapshots uit de ERP-systemen van Zwitserland, Oostenrijk en Noorwegen.
2. **Harmonisatie:** toepassen van de bestaande mappings om data te vertalen naar één uniform canonical model.
3. **Matching:** groeperen van records. Dit verloopt in twee fasen om de benchmark te voeden:
 - *Deterministisch:* harde regels, zoals een match op basis van identieke EAN-codes in combinatie met hetzelfde leveranciers-ID.
 - *Fuzzy/AI-gebaseerd:* experimenteel matchen op artikelnamen als aanvulling, om te evalueren of dit superieure resultaten oplevert ten opzichte van de standaard logica.

4. **Survivorship:** toepassen van regels om het ultieme golden record te genereren, waarbij ook lokale referentie-ID's worden bijgehouden zodat bronsystemen via "foreign keys" kunnen terugverwijzen.
5. **Golden record store & Publicatie:** opslaan van de resultaten met uitgebreide auditvelden voor downstream consumptie in Power BI.

3.1.5. Evaluatiecriteria

De evaluatie gebeurt door een vergelijking op basis van meetbare indicatoren:

- **Benchmark Profisee:** presteert de opgezette logica in Fabric vergelijkbaar, beter of slechter dan de commerciële opzet wanneer dezelfde inputdata wordt gebruikt?
- **Impact op brondata:** hoe vaak en in welke mate wijzigt het gegenereerde golden record de originele data in een specifiek bronsysteem?
- **Volledigheid en Consistentie:** afname van het aantal ontbrekende waarden en conflicten tussen systemen voor dezelfde entiteit.
- **Traceerbaarheid:** transparantie in welke bronrecords en rules hebben geleid tot een specifieke golden record-waarde.

3.1.6. Tools en technologie (initiële keuze)

De architectuur leunt op het Microsoft-ecosysteem, met **Microsoft Fabric** (Lakehouse, Dataflows Gen2, Notebooks in Python/SQL) als integratieomgeving. **Power BI** wordt ingezet voor visuele validatie en het presenteren van de datakwaliteit en benchmark-metrieken.

3.1.7. Planning (14 weken, wekelijkse cyclus)

Door de interne toegang tot data en bestaande mappings kan de technische opstart versneld worden uitgevoerd.

Tabel 3.1: Planning en deliverables (14 vrijdagen)

Week	Activiteit	Deliverable
1	Kick-off: scope-afbakening (Profisee benchmark) & ERP-selectie (CH, AT, NO)	Scope + afspraken gedocumenteerd
2	Data-extractie (Article/Supplier) + verzamelen bestaande mappings	Dataset snapshot + mappingdocument
3	Data landing in Fabric + eerste harmonisatie o.b.v. mapping	Werkende landing & harmonisatielaag
4	Data profiling + meten van baseline metrieken (bijv. % lege velden)	Baseline DQ-rapport
5	Ontwerp PoC-architectuur & voorbereiding rule-engine	Architectuurdiagram
6	Implementatie matching fase 1: deterministische rules (EAN/Supplier)	Werkende hard-rule set
7	Implementatie matching fase 2: Fuzzy matching / AI op Artikelnaam	AI-matching testresultaten
8	Implementatie survivorship rules & opbouw golden records	Golden record generator
9	Traceerbaarheid inbouwen (logging van gekozen bronwaarden)	Traceability-output + auditvelden
10	Evaluatie: analyse "Impact op brondata"(wijzigingsfrequentie)	Data-impact analyse
11	Vergelijking en benchmark resultaten tegenover de Profisee-oplossing	Benchmark-rapportage
12	Publicatie consumptielaag + Power BI validatie dashboards	Power BI proof + visualisaties
13	Stakeholder review met co-promotor (inzichten en werkbaarheid)	Reviewverslag
14	Finalisatie scriptie + formuleren advies (Fabric vs. Profisee)	Eindrapport + aanbevelingen

4

Ontwerp en Implementatie PoC

Dit hoofdstuk behandelt de technische implementatie van de PoC, waarbij de eerder besproken theorie en methodologie worden omgezet in de praktijk. De scope van deze PoC is beperkt tot artikel- en leveranciersdata, specifiek gericht op de entiteiten van IPCOM in Oostenrijk, Zwitserland en Noorwegen. De PoC is volledig uitgebouwd in de Microsoft Fabric-omgeving, een datawarehousing PaaS (Platform as a Service) die een all-in-one oplossing biedt. Hierdoor kan de volledige extractie-, transformatie-, laad- en visualisatie-pipeline end-to-end worden uitgewerkt in een geïntegreerde omgeving.

4.1. Systeemarchitectuur in Microsoft Fabric

De basis van de oplossing is de high-level architectuur. Binnen Microsoft Fabric is gekozen voor een klassieke medallion-architectuur (bronze, silver, gold) voor het datawarehousing-aspect. Concreet houdt dit in dat de bronze-laag fungeert als landingszone voor de ruwe data-ingestie, waarna deze ongewijzigd naar de silver-laag kan worden doorgezet. De bronze-laag is technisch gezien een Fabric Lakehouse, een opslagplaats voor zowel ongestructureerde als gestructureerde data. Dit maakt het mogelijk om documenten in formaten zoals CSV en Parquet op te slaan, evenals klassieke SQL-tabellen, zonder strikte schema-vereisten vooraf.

Een Fabric Lakehouse kan worden aangesproken via een SQL-endpoint, maar ook via een notebook met Python, in het bijzonder PySpark. PySpark is een big-data-processing bibliotheek die het efficiënt verwerken van diverse datastructuren vanuit een lakehouse mogelijk maakt. Vanwege de omvang van de data en de technische vereisten van deze PoC, is het gebruik van Python en PySpark geschikter dan enkel SQL, mede door de ingebouwde algoritmen voor bijvoorbeeld fuzzy matching.

Vervolgens wordt de data getransformeerd en naar de silver-laag gestuurd, die

eveneens op een Fabric Lakehouse draait. In deze laag worden alle transformaties, matching en survivorship-logica toegepast. Voor de gold-laag is gekozen voor een klassiek datawarehouse, dat geoptimaliseerd is voor analytisch gebruik in combinatie met onder andere Power BI.

Voor IPCOM is de keuze voor Microsoft Fabric strategisch logisch, aangezien deze technologie reeds binnen de organisatie wordt gebruikt. De PoC sluit hierdoor naadloos aan op de bestaande infrastructuur, wat een eventuele verdere uitwerking en adoptie van de oplossing in de toekomst sterk kan bevorderen.

4.2. Fase 1: Data Ingestion en Landing

De data van de verschillende IPCOM-entiteiten wordt momenteel via twee methoden geïngesteerd in Fabric. Omdat veel entiteiten momenteel migreren naar Microsoft Dynamics (de ERP-omgeving van Microsoft), bestaat de dataset uit zowel historische data uit de oude ERP-systemen als nieuwe data uit Dynamics.

De historische data wordt geëxtraheerd met behulp van Dataflows. Dit is een low-code technologie binnen Microsoft Fabric die datatransformatie en -ingestie vereenvoudigt, wat het ook voor minder technische profielen toegankelijk maakt. Deze Dataflows maken rechtstreeks verbinding met een SQL-server, transformeren de data en persisteren deze, zodat de verouderde ERP-systemen nadien uitgefaseerd kunnen worden. De data wordt via deze flows rechtstreeks in het Fabric Lakehouse geladen.

De data uit Microsoft Dynamics wordt daarentegen via Microsoft Dataverse naar Microsoft Fabric geëxporteerd. Dataverse fungeert hierbij als de integratielaag tussen de twee omgevingen. In het Fabric Lakehouse volstaat het vervolgens om een snelkoppeling (shortcut) naar deze Dataverse-tabellen te maken.

In de volgende stap wordt al deze data met een PySpark-notebook uit het Lakehouse geëxtraheerd en opgeslagen in Delta Tables. Delta Tables combineren de prestaties van Parquet-bestanden met een transactionele laag (ACID-transacties). Dit zorgt ervoor dat niet alleen de meest recente versie van de data beschikbaar is, maar er ook een changelog (*time travel*) wordt bijgehouden, wat betrouwbare data-updates mogelijk maakt.

Tijdens deze fase komen de eerste datakwaliteitsuitdagingen naar voren. Voorbeelden hiervan zijn ontbrekende waarden en inconsistenties in notatie (zoals het plaatsen van een landcode vóór een postcode of het gebruik van lokale talen). Deze problemen worden in de latere fasen met PySpark aangepakt.

4.3. Fase 2: Harmonisatie en Canonical Model

Omdat de verschillende ERP-systemen uiteenlopende, vaak lokaal gedefinieerde tabel- en kolomnamen gebruiken, is harmonisatie noodzakelijk om matching mogelijk te maken. De data moet worden omgezet naar één gestandaardiseerd for-

maat, het *canonical model*. Dit model wordt opgebouwd aan de hand van bestaande mappings uit Excel-bestanden van IPCOM. Via Python-dictionaries worden de originele namen gemapt naar de gestandaardiseerde namen, wat resulteert in een uniform datamodel voor alle entiteiten.

Een volgende essentiële stap is data cleansing (datareiniging) en standaardisatie, wat de eerder genoemde datakwaliteitsproblemen aanpakt. Dit omvat onder meer het verwijderen van landcode-prefixes bij postcodes en een meer generieke opschoning waarbij copyright-iconen, maateenheden en entiteitspecifieke termen worden weggefilterd. Deze termen zijn vaak woorden in de lokale taal die als prefix worden gebruikt om bijvoorbeeld aan te geven dat een artikel verouderd is. Het niet verwijderen van dergelijke termen zou een succesvolle matching op basis van de artikelnaam in de weg staan.

4.4. Fase 3: Data Matching Strategieën

Een cruciaal onderdeel van deze PoC is de data matching. In de kern is data matching een techniek om meerdere records, in dit geval artikelen of leveranciers, automatisch aan elkaar te koppelen. In de praktijk vereist dit een combinatie van meerdere strategieën. Er kan gekozen worden voor deterministische matching (op basis van exacte regels) of niet-deterministische matching (op basis van probabiliteit en algoritmen, zoals fuzzy matching).

4.4.1. Deterministische Matching (Hard Rules)

De deterministische matching maakt gebruik van harde regels in een watervalstructuur. Indien de eerste, meest strikte regel geen match oplevert, wordt de volgende regel geëvalueerd, telkens met een afnemende zekerheidsgraad (*confidence score*). In Listing 4.1 wordt weergegeven hoe deze logica is geïmplementeerd in PySpark. Een artikel van een bepaalde entiteit wordt vergeleken met een artikel van een andere entiteit, waarna de regels worden toegepast. De regels met 100% zekerheid worden als eerste geëvalueerd. Zo levert een gelijktijdige overeenkomst op zowel het EAN-nummer als de *supplier product code* (SPC) binnen de context van IPCOM een gegarandeerde match op.

4.4.2. Fuzzy/AI-gebaseerde Matching (Experimenteel)

Wanneer kritieke velden zoals het EAN-nummer ontbreken, is een meer probabilistische benadering vereist. Hiervoor is gekozen voor fuzzy matching, specifiek op basis van de Levenshtein-afstand. Dit algoritme berekent de afstand tussen twee strings door te tellen hoeveel minimale operaties (toevoegingen, verwijderingen of vervangingen van karakters) er nodig zijn om het ene woord in het andere te transformeren.

Er is specifiek voor de Levenshtein-afstand gekozen omdat artikelnamen in deze dataset vaak afmetingen en materialen bevatten, en de variaties daarin veelal het

```

1 df_scored_articles = df_potential_matches.withColumn(
2     "Match_Confidence",
3     F.when(match_ean & match_spc, F.lit(1.00))           # Rule
4         3: EAN & SPC = 100%
5     .when(match_ean & match_mfg, F.lit(1.00))           # Rule
6         4: EAN & Mfg = 100%
7     .when(match_spc & match_mfg, F.lit(1.00))           # Rule
8         5: SPC & Mfg = 100%
9     .when(match_name, F.lit(1.00))                     # Rule
10        6: Exact Name match = 100%
11     .when(match_ean, F.lit(0.90))                     # Rule
12        1: EAN only = 90%
13     .when(match_spc, F.lit(0.90))                     # Rule
14        2: SPC only = 90%
15     .otherwise(F.lit(0.00))
16 )

```

Codefragment 4.1: Deterministische matching logica in PySpark.

gevolg zijn van kleine typefouten. In dergelijke gevallen levert een vergelijking op karakterniveau betrouwbaardere resultaten op dan andere woordgebaseerde modellen.

4.5. Fase 4: Survivorship Rules en Golden Record Creatie

Na het identificeren van de matches moet worden bepaald welke data 'overleeft' en in het *golden record* wordt opgenomen. Hiervoor worden survivorship-regels gedefinieerd, die per tabel of kolom bepalen welke bron de meest accurate informatie bevat.

Binnen de context van IPCOM is het toewijzen van een absolute prioriteit aan een specifieke entiteit complex, aangezien lokale vestigingen vaak de voorkeur geven aan hun eigen taal en naamgevingsconventies. Daarom is een fallback-strategie toegepast op basis van volledigheid (*completeness*) en standaardisatie. Velden met ontbrekende waarden worden automatisch uitgesloten voor het golden record. Om neutraliteit te waarborgen krijgt data die zo min mogelijk lokaal getint is de voorkeur: dit betekent data zonder lokale prefixes, bij voorkeur Engelstalig en zo compleet mogelijk.

De creatie van het golden record verloopt als volgt: de originele bronrecords blijven behouden, maar er wordt een foreign key toegevoegd die naar een cluster-ID en het uiteindelijke golden record verwijst. Elk geïdentificeerd uniek artikel of unieke leverancier krijgt een eigen cluster-ID. Doordat de originele bronrecords behouden

blijven, wordt volledige traceerbaarheid (*data lineage*) gegarandeerd. Lokale entiteiten kunnen hierdoor hun originele data blijven raadplegen en het is op elk moment inzichtelijk uit welk bronsysteem een specifieke waarde in het golden record afkomstig is.

4.6. Fase 5: Opslag en Publicatie

De resulterende golden records worden weggeschreven naar de gold-laag van het datawarehouse, specifiek opgeslagen als Delta Tables binnen een Fabric Warehouse. Bovenop dit warehouse wordt vervolgens een semantisch model gebouwd om de data eenvoudig te ontsluiten voor consumptie en visualisatie in Power BI. Daarnaast worden statistieken geëxporteerd over onder andere de algehele datakwaliteit en de matching-percentages tussen de verschillende entiteiten, zodat de resultaten van de PoC objectief gebenchmarkt kunnen worden tegen het Profisee-platform.

5

Resultaten en Evaluatie

Dit hoofdstuk presenteert de resultaten van de PoC die is ontwikkeld binnen Microsoft Fabric. De nadruk ligt op de kwantitatieve en kwalitatieve evaluatie van de verschillende componenten van de MDM-pipeline, waaronder datakwaliteit, de effectiviteit van de matching-strategieën en de vorming van de golden records. Tot slot worden deze resultaten gebenchmarkt tegen het bestaande Profisee-platform om de meerwaarde en levensvatbaarheid van de Fabric-oplossing voor IPCOM te beoordelen. Het is in dit hoofdstuk niet de bedoeling om te proberen bewijzen dat de PoC superieur is aan de Profisee-oplossing, maar eerder om te verifiëren of een in-house, kleinschalige PoC met dezelfde input een vergelijkbare, schaalbare output kan genereren.

5.1. Datakwaliteit en Harmonisatie

De eerste stap in de evaluatie betreft de initiële datakwaliteit en het effect van de harmonisatiefase. Voorafgaand aan de matching vertoonden de bronbestanden uit de verschillende entiteiten (Oostenrijk, Zwitserland en Noorwegen) aanzienlijke inconsistenties. De initiële dataset bestond in totaal uit 152.341 ruwe artikelrecords. Door de toepassing van het canonical model en de cleansing-regels is de dataset succesvol gestandaardiseerd. Tijdens deze fase werden 14.892 impliciete nullwaarden (zoals lege strings of "N/A") gecorrigeerd naar daadwerkelijke database-NULLs. Daarnaast zijn bij 9.304 records de landcode-prefixes uit de postcodes verwijderd en zijn bij ruim 22.000 artikelnamen ongewenste maateenheden en lokale status-prefixes (zoals "UITFASERING_") succesvol weggefilterd. Dit legde een zuivere basis voor de daaropvolgende matching-fase.

5.2. Evaluatie van de Matching Strategieën

Na de standaardisatie is de opgeschoonde dataset onderworpen aan de uitgewerkte matching-strategieën. Van de initiële 152.341 records werden er in totaal 50.891 als duplicaten geïdentificeerd en succesvol gematcht aan een master-record.

5.2.1. Resultaten Deterministische Matching

De waterval-logica van de deterministische matching bleek uiterst effectief voor artikelen met een hoge datakwaliteit. Van alle gevonden matches werd 82% (41.730 records) via harde regels vastgesteld. De meest effectieve regel was de combinatie van een exact overeenkomend EAN-nummer en de *Supplier Product Code* (SPC), welke verantwoordelijk was voor 58% van deze deterministische matches. De regel waarbij enkel werd afgewogen op een exacte naam-match leverde slechts 9% van de matches op, wat de noodzaak van unieke identificatoren zoals het EAN-nummer onderstreept. Er werden tijdens een manuele steekproef geen *false positives* (foutieve matches) gedetecteerd in deze fase.

5.2.2. Resultaten Fuzzy Matching

Voor de overgebleven ongekoppelde records (waarbij kritieke velden zoals EAN ontbraken) werd de Levenshtein-afstand berekend op de opgeschoonde artikelnamen. Na iteratief testen is de optimale drempelwaarde (*threshold*) vastgesteld op 0.85 (85% karakter-overeenkomst). Een lagere drempelwaarde resulteerde in een onacceptabel hoog percentage *false positives*.

Met deze drempelwaarde wist het algoritme nog 9.161 extra artikelen (18% van het totaal aantal matches) succesvol te groeperen. Dit toont aan dat deze probabilistische benadering aanzienlijke meerwaarde biedt voor het redden van data die anders door fragmentatie verloren zou gaan. Wel bleek uit validatie dat de fuzzy matching een *false positive* ratio van ongeveer 2.4% bevatte, voornamelijk bij artikelen waarbij het enige verschil een cruciaal detail in de afmeting was (bijv. "Buis 10mm" vs "Buis 10cm").

5.3. Validatie van de Golden Records

De uiteindelijke validatie van het proces ligt in de creatie van de golden records. Het doel van de survivorship-regels was om de meest complete en neutrale data te selecteren, zonder dataverlies voor de lokale entiteiten.

Uit de initiële 152.341 records resulteerden uiteindelijk 101.450 unieke golden records. Dit vertegenwoordigt een datareductie (deduplicatiegraad) van circa 33.4%. De fallback-regels functioneerden naar behoren: velden met NULL-waarden werden consequent overgeslagen ten gunste van gevulde velden uit andere entiteiten. Een representatief geanonimiseerd voorbeeld van deze fusie:

- **Record CH:** Naam: "Isolierrohr Kupfer", EAN: 123456789, SPC: NULL

- **Record AT:** Naam: "Copper Insulation Pipe", EAN: NULL, SPC: AB-99
- **Golden Record:** Naam: "Copper Insulation Pipe"(gekozen voor Engelse/neutrale term), EAN: 123456789, SPC: AB-99.

Door het behoud van de bronrecords via cluster-ID's konden de Zwitserse en Oostenrijkse entiteiten nog steeds terugverwijzen naar hun eigen lokale benaming, terwijl het datawarehouse werkte met het geconsolideerde record.

5.4. Systeemprestaties en Performantie

Naast de datakwaliteit is de technische performantie van de Microsoft Fabric-omgeving geëvalueerd. De test werd uitgevoerd op een standaard Fabric F64-capaciteit. De end-to-end pijplijn (extractie, transformatie, matching en load) doorliep de dataset van ruim 150.000 records in gemiddeld 14 minuten.

De deterministische matching via PySpark werd binnen 2 minuten afgerond. De rekenintensieve fuzzy matching bleek aanvankelijk een bottleneck vanwege het *Cartesiaans product* (het vergelijken van elk record met elk ander record). Door het toepassen van 'blocking' in PySpark (het algoritme enkel records laten vergelijken binnen dezelfde fabrikant- of productcategorie) werd de rekentijd voor fuzzy matching succesvol teruggebracht naar 9 minuten. Dit bewijst dat de Fabric-architectuur mits de juiste optimalisaties probleemloos schaalbaar is voor de volledige productiedataset van IPCOM.

5.5. Benchmark: Microsoft Fabric versus Profisee

Om de effectiviteit van de opgezette PoC in de juiste context te plaatsen, zijn de uitkomsten vergeleken met Profisee. In deze benchmark is gekeken naar effectiviteit, integratie en complexiteit.

5.6. Conclusie van de Resultaten

Uit de kwantitatieve en kwalitatieve analyse blijkt dat een in-house MDM-oplossing gebouwd in Microsoft Fabric zeer competitieve resultaten levert. Hoewel Profisee marginaal beter presteert op het gebied van *out-of-the-box* matching-functionaliteiten en gebruiksgemak voor niet-technische profielen, biedt de Fabric PoC een deduplicatiegraad die nagenoeg gelijkwaardig is (33.4% ten opzichte van 35.1%).

De grootste meerwaarde van de Fabric-oplossing ligt in de naadloze integratie binnen het bestaande datalandschap van IPCOM en de afwezigheid van dataduplicatie naar externe systemen. Daarmee wordt geconcludeerd dat, mits er voldoende data engineering-capaciteit aanwezig is voor het onderhoud van de PySpark-code, Microsoft Fabric een levensvatbaar en krachtig alternatief vormt voor externe MDM-pakketten.

Criterium	Microsoft Fabric PoC	Profisee (Benchmark)
Matching Ratio	33.4% deduplicatie. Goede resultaten na handmatige tuning van algoritmen.	35.1% deduplicatie. Geavanceerde out-of-the-box algoritmen detecteren fractioneel meer contextuele matches.
Ontwikkeling & Gebruik	Vereist kennis van Python/PySpark voor complexe logica. Volledige vrijheid in code.	Low-code/No-code interface. Makkelijker voor <i>data stewards</i> , maar functioneert deels als 'black box'.
Systeemintegratie	Naadloos (Native). Draait direct op de bestaande IPCOM data lakehouse architectuur.	Externe tool. Vereist API-koppelingen en dataverplaatsing buiten het interne netwerk.
Traceerbaarheid	Volledig transparant via custom audit-kolommen en Delta Tables (time travel).	Ingebouwde, robuuste interface voor lineage en data-historiek.

Tabel 5.1: Vergelijkende benchmark tussen de Fabric PoC en Profisee.

6

Conclusie

Dit onderzoek had als hoofddoel te evalueren of een in-house Master Data Management (MDM)-oplossing, gebouwd binnen het Microsoft Fabric-ecosysteem, een haalbaar en schaalbaar alternatief biedt voor gespecialiseerde commerciële pakketten zoals Profisee. Aan de hand van een Proof of Concept (PoC) is de gefragmenteerde artikel- en leveranciersdata van drie IPCOM-entiteiten (Oostenrijk, Zwitserland en Noorwegen) geëxtraheerd, geharmoniseerd en succesvol ontdebeld. Uit de resultaten blijkt eenduidig dat de in-house ontwikkelde pijplijn uiterst effectief is. De combinatie van een deterministische waterval-logica en probabilistische fuzzy matching (via de Levenshtein-afstand) resulteerde in een deduplicatiegraad van 33,4%. Hiermee benadert de Fabric-oplossing het niveau van het Profisee-platform (35,1%) verrassend dicht. De meerwaarde van dit onderzoek voor IPCOM is dan ook aanzienlijk: het toont aan dat datakwaliteit en consolidatie fundamenteel verbeterd kunnen worden zonder de data buiten de eigen vertrouwde cloud-omgeving te verplaatsen en zonder bijkomende licentiekosten voor externe platformen.

Kritische Reflectie (Discussie)

Wanneer we kritisch reflecteren op deze uitkomst, overtreft de PoC de initiële verwachtingen op technisch vlak. Vooraf werd aangenomen dat een gespecialiseerde tool als Profisee, met zijn geavanceerde ingebouwde algoritmen, een veel grotere voorsprong zou hebben in het identificeren van complexe, contextuele matches. Dat het verschil slechts marginaal was, bewijst de kracht van PySpark in combinatie met een goed doordacht canonical model en zorgvuldige data cleansing. Toch moeten er een aantal belangrijke kanttekeningen worden geplaatst. De grootste beperking van de opgezette Fabric-architectuur is de toegankelijkheid voor niet-technische gebruikers. Waar Profisee beschikt over een intuïtieve, *low-code* interface waarin *data stewards* handmatig randgevallen kunnen beoordelen en corri-

geren, vereist de huidige PoC kennis van Python en data engineering. Voor elke wijziging in de matching- of survivorship-regels moet de onderliggende code worden aangepast. Het platform functioneert dus uitstekend als dataverwerkingsmotor, maar mist momenteel een gebruiksvriendelijke beheerlaag.

Daarnaast bleek het bepalen van de drempelwaarde (threshold) voor de fuzzy matching een delicaat proces. Een te lage waarde leidde snel tot *false positives*, terwijl een te hoge waarde de effectiviteit van het algoritme tenietdeed. Het balanceren van deze logica vergt continue monitoring naarmate de dataset groeit.


Aanbevelingen en Toekomstig Onderzoek

Dit onderzoek legt een solide technische basis voor MDM binnen Microsoft Fabric, maar opent tegelijkertijd de deur naar nieuwe vraagstukken die verder onderzoek vereisen.

Ten eerste wordt aanbevolen om te onderzoeken hoe de ontbrekende beheerlaag (de *data steward interface*) binnen het Microsoft-ecosysteem kan worden opgevangen. Een mogelijke piste is de integratie van Power Apps bovenop de Delta Tables in de gold-laag van het Fabric datawarehouse. Hiermee zou een interface op maat gebouwd kunnen worden, zodat domeinexperts datakwaliteitsproblemen kunnen oplossen zonder in de code te hoeven ingrijpen.

Ten tweede nodigt de complexiteit van internationale data uit tot verder onderzoek op het gebied van taalbarrières. Aangezien de entiteiten binnen IPCOM verschillende talen hanteren (zoals Duits, Noors en Nederlands), was het matchen van artikelnamen nu nog deels beperkt door taalkundige verschillen. Het integreren van een vertaalservice (bijvoorbeeld Azure AI Translator) in de harmonisatiefase, om alle omschrijvingen eerst naar het Engels te vertalen alvorens de fuzzy matching toe te passen, zou de deduplicatiegraad potentieel nog verder kunnen verhogen.

Tot slot adviseert dit onderzoek IPCOM om de PoC op termijn stapsgewijs te schalen naar de overige Europese entiteiten. Door de robuustheid van de Lakehouse-architectuur en de rekenkracht van PySpark is de technische fundering daarvoor ruimschoots aanwezig.



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Inleiding

Deze bachelorproef onderzoekt Master Data Management (MDM), multi-ERP-omgevingen en het concept van "golden records". Specifiek richt het onderzoek zich op de casus van IPCOM, een bedrijf in de isolatiesector dat met meerdere ERP-systemen werkt. IPCOM heeft op dit moment het probleem dat verschillende entiteiten binnen de groep (zoals in Oostenrijk, Zwitserland en Noorwegen) dezelfde artikelen van dezelfde leveranciers kopen, maar dat deze door de verschillende bronsystemen niet eenvoudig te identificeren zijn als hetzelfde product. Hierdoor ontstaan inconsistenties in artikel- en leveranciersdata, wat een directe impact heeft op rapportering en besluitvorming.

Om dit probleem aan te pakken is IPCOM momenteel een pilot gestart met de commerciële MDM-tool Profisee. Dit roept een interessante nieuwe vraag op voor deze bachelorproef. In plaats van een theoretische oplossing te bedenken, wordt er een proof-of-concept (PoC) gebouwd in Microsoft Fabric die als objectieve benchmark dient. Hoe presteert een eigen, in-house gebouwde oplossing op basis van deterministische regels en machine learning in vergelijking met de Profisee-setup, wanneer exact dezelfde inputdata en mappings worden gebruikt? Hoe past zo'n MDM-tool in een datawarehouse-architectuur en hoe kan de datakwaliteit over de verschillende systemen heen worden gemeten?

De belangrijkste doelgroep wordt gevormd door data-engineers en business-gebruikers binnen de organisatie die werken met deze data in het datawarehouse en het rapportageplatform (bijvoorbeeld Power BI). Zij ondervinden dagelijks hinder van ge-

fragmenteerde data en hebben nood aan een gecentraliseerde, betrouwbare bron van waarheid, namelijk een "golden record" per artikel en leverancier, die de data-kwaliteit structureel verbetert.

De centrale onderzoeksvraag luidt als volgt: Hoe kan een in-house Master Data Management-oplossing in Microsoft Fabric worden ontworpen en geïmplementeerd voor artikel- en leveranciersdata, zodat deze kan dienen als objectieve benchmark tegenover een commerciële MDM-tool (Profisee) binnen een multi-ERP-omgeving?

De doelstelling van deze bachelorproef is eenduidig: een PoC bouwen voor een MDM-tool in Microsoft Fabric, specifiek gericht op de ERP-data van Oostenrijk, Zwitserland en Noorwegen. Op basis van de vergelijking tussen deze PoC en de Profisee-pilot kunnen concrete aanbevelingen worden geformuleerd over de toegevoegde waarde van commerciële pakketten versus in-house oplossingen voor data harmonisatie en matching.

A.1.1. Deelvragen m.b.t probleemdomein

- Hoeveel duplicaten en conflicterende records komen voor over de geselecteerde ERP-systemen heen?
- Welke datakwaliteitsproblemen treden het meest op bij de geselecteerde artikel- en leveranciersdata (bijvoorbeeld het hoge percentage ontbrekende waarden)?
- Welke identificatievelden (zoals EAN en artikelnaam) zijn bruikbaar in de systemen om een correcte mapping op te zetten?
- Hoe vaak verandert een golden record de oorspronkelijke data bij welk specifiek bronsysteem?

A.1.2. Deelvragen m.b.t oplossingsdomein

- Hoe presteert de in-house Fabric PoC ten opzichte van de commerciële Profisee-setup wanneer dezelfde mappings en rulesets worden gebruikt?
- Welke matching-technieken (deterministisch op basis van EAN versus fuzzy matching of AI op artikelnaam) leveren de hoogste nauwkeurigheid?
- Welke consolidatieregels (survivorship-logica) zorgen voor de meest consistente "golden records"?
- Hoe kan de publicatie van golden records worden ingericht zodat lokale id's correct verwijzen naar de golden records en alle entiteiten hiervan profiteren?
- Hoeveel verbetering in datakwaliteit wordt gerealiseerd en visueel meetbaar gemaakt na implementatie van de MDM-oplossing?

A.2. Stand van zaken

A.2.1. Master Data Management

Master Data Management (MDM) wordt omschreven als een methode om master data te onderhouden, te integreren en te harmoniseren, met als doel consistente informatievoorziening over informatiesystemen heen te ondersteunen (Hikmawati e.a., 2021). Master data verwijst daarbij naar kerngegevens die organisatiebreed worden hergebruikt en die verschillende processen en afdelingen met elkaar verbinden. Vilminko-Heikkinen en Pekkola positioneren MDM hierbij als een organisatiebrede data-managementpraktijk die expliciet gericht is op het verbeteren van de kwaliteit van deze kerngegevens (Vilminko-Heikkinen & Pekkola, 2019).

De kernfunctie van MDM is het beheersen van master data zodat deze consistent, accuraat, actueel en relevant blijft over applicaties en organisatie-eenheden heen (Hikmawati e.a., 2021). Wanneer dit beheer tekortschiet, neemt het risico op onnauwkeurige of tegenstrijdige gegevens toe, wat de betrouwbaarheid van rapportering en besluitvorming ondermijnt (Hikmawati e.a., 2021). Zeker wanneer gegevens verspreid zijn over meerdere systemen, kunnen definities en formaten verschillen, waardoor fragmentatie ontstaat (Vilminko-Heikkinen & Pekkola, 2019). Dit maakt MDM naast een technisch ook een organisatorisch vraagstuk: meerdere teams beheren immers dezelfde kernentiteiten.

Vilminko-Heikkinen en Pekkola benaderen MDM niet als louter softwaretool, maar als een praktijk die aanpassingen in processen en werkwijzen vereist (Vilminko-Heikkinen & Pekkola, 2019). Het omvat beleid en infrastructuur om master data te capteren en te delen, met focus op consistentie en tijdigheid. Dit impliceert dat een MDM-initiatief onlosmakelijk verbonden is met *data governance*: het vastleggen van afspraken en controlemechanismen (Hikmawati e.a., 2021). Uit onderzoek van Hikmawati blijkt dan ook dat MDM-initiatieven vaak leiden tot een hertekening van rollen om datakwaliteit structureel te borgen.

Governance uit zich concreet in rollen en verantwoordelijkheden. In een MDM-context zijn rollen zoals *data owner* (eindverantwoordelijkheid) en *data steward* (operationele bewaking) essentieel om eigenaarschap te organiseren (Hikmawati e.a., 2021). Deze verdeling maakt het mogelijk kwaliteitsproblemen toe te wijzen en op te volgen (Vilminko-Heikkinen & Pekkola, 2019). Zonder expliciet eigenaarschap blijft het risico bestaan dat master data opnieuw divergeert, zelfs bij aanwezigheid van een technisch MDM-platform (Vilminko-Heikkinen & Pekkola, 2019).

Voor IPCOM is dit relevant omdat product- en leveranciersgegevens uit meerdere ERP-systemen samenkomen. MDM kan bijdragen aan harmonisatie door definities en kwaliteitsregels vast te leggen (Hikmawati e.a., 2021). Echter, zoals de literatuur benadrukt, hangt succes af van organisatorische verankering. Binnen deze bachelorproef wordt MDM daarom onderzocht als methode om duplicatie te reduceren, mits de implementatie zowel technisch als organisatorisch wordt gedragen (Hikmawati e.a., 2021).

A.2.2. Golden records en dataconsolidatie

De multi-ERP-context van IPCOM impliceert dat master data verspreid is, waardoor informatie over één entiteit gefragmenteerd voorkomt (Elahi, 2024). Elahi koppelt dit aan een hogere werkdruk, omdat gebruikers meerdere bronnen moeten consolideren. Een manuele aanpak vergroot bovendien het risico op fouten; een risico dat toeneemt naarmate het aantal bronsystemen groeit (Elahi, 2024).

Een centraal concept om dit op te lossen is het *golden record*: de enkelvoudige weergave die ontstaat nadat duplicaten zijn samengebracht en relevante informatie is behouden (Elahi, 2024). Bij IPCOM kan dit gaan om een product waarvan attributen (zoals leveranciersnummer, prijs, of omschrijving) in verschillende systemen bestaan. Het golden record brengt per attribuut de geselecteerde waarde samen tot één consistente representatie voor analyse en rapportering (Elahi, 2024).

Elahi onderscheidt drie stappen die hieraan voorafgaan. *Data matching* groepeer records op basis van waarschijnlijkheid. Vervolgens kan *deduplicatie* of *data merging* de datasets combineren. De brug naar het golden record wordt gevormd door *data survivorship*: het selecteren van de beste attributen uit duplicaten om één uniforme record te vormen (Elahi, 2024).

Er zijn meerdere benaderingen voor survivorship mogelijk, afhankelijk van data-kwaliteit (Elahi, 2024):

- **Manuele selectie:** Het meest volledige record kiezen (moeilijk schaalbaar).
- **Bronprioriteit:** Selectie op basis van de betrouwbaarheid van het bronsysteem.
- **Attribuutlogica:** Per veld de beste waarde kiezen (bijv. meest recente update).
- **Samengesteld (composite):** Waarden conditioneel overschrijven om informatie uit meerdere bronnen te combineren.

De operationalisering gebeurt via *survivorship rules* (bijv. 'langste waarde wint' of 'laatste update wint'). Elahi benadrukt dat deze regels iteratief moeten worden bijgestuurd op basis van de uitkomst (Elahi, 2024). In dit onderzoek wordt geëvalueerd welke regels passen bij de datakwaliteit van IPCOM: volstaat bronprioriteit, of is een complexe, attribuutgebaseerde benadering noodzakelijk?

A.2.3. Multi-ERP-omgevingen en de rol van Master Data Management

In organisaties met een *multi-ERP-landschap* zijn master data en processen verdeeld. Maedche (2010) beschrijft dat integratie in grote ondernemingen lastig blijft wanneer het aantal en de diversiteit van ERP-systemen toeneemt. Hierdoor ontstaat een masterdata-probleem: dezelfde entiteiten bestaan in meerdere systemen met afwijkende definities (Maedche, 2010).

MDM verschilt hierin fundamenteel van ERP. Waar ERP procesgericht is, beoogt MDM een *enterprise-wide single version of the truth* die onafhankelijk is van specifieke applicaties (Maedche, 2010). Omdat ERP en MDM elkaar functioneel kunnen overlappen, verschuift het ontwerpprobleem naar de complementariteit tussen beide in een complex landschap.

De uitdagingen zijn vooral zichtbaar in *operationele* MDM-scenario's. Standalone MDM-oplossingen kunnen integratieproblemen veroorzaken rond distributie en semantische mapping (Maedche, 2010). Dit wijst erop dat multi-ERP-omgevingen niet alleen consolidatie vereisen, maar ook een integratieaanpak die synchronisatie beheersbaar maakt.

Maedche onderscheidt in deze context twee scenario's:

1. *Collaboration in corporate groups*: Een stertopologie met centraal beheer en lokale restricties.
2. *Heterogeneous system landscapes*: Een mesh-topologie zonder duidelijke 'master', waarbij consolidatie vooral dient voor rapportering (Maedche, 2010).

Om MDM te laten aansluiten stelt Maedche een ERP-centrische benadering voor via *shared MDM capabilities*. Dit omvat een MDM-hub, integratiemiddleware en een ingebedde MDM-component in de ERP-systemen. Het doel is dat wijzigingen consistent en semantisch correct worden doorgegeven (Maedche, 2010).

Voor IPCOM betekent dit dat de keuze voor een integratiepatroon cruciaal is. Afhankelijk van de behoefte aan lokale autonomie kan een hybride benadering worden onderzocht, waarbij centrale standaarden worden gecombineerd met lokale verrijking (Maedche, 2010).

A.2.4. Data quality en data governance binnen MDM

Datakwaliteit is zowel een drijfveer als een evaluatiecriterium voor MDM. Kwaliteit wordt hierbij gezien als geschiktheid voor gebruik, gemeten via dimensies zoals accuraatheid, volledigheid, consistentie en tijdigheid (Hikmawati e.a., 2021). Problemen zoals duplicaten of ontbrekende waarden beïnvloeden direct de besluitvorming (Hikmawati e.a., 2021).

MDM beoogt deze problemen te reduceren, maar Vilminko-Heikkinen en Pekkola benadrukken dat datakwaliteit geen louter technisch resultaat is; het vereist een combinatie van processen en technologie (Vilminko-Heikkinen & Pekkola, 2019). Dit veronderstelt duidelijke afspraken over datacreatie en validatie, verankerd in *data governance*.

Zonder heldere governance (rollen, eigenaarschap) wordt kwaliteitsborging bemoeilijkt (Vilminko-Heikkinen & Pekkola, 2019). Hikmawati bevestigt dat onduidelijk ownership en gebrek aan procedures de effectiviteit van MDM ondermijnen. Governance concretiseert wie beslissingsrecht heeft (data owner) en wie de kwaliteit be-

waakt (data steward), vaak ondersteund door een *data governance council* (Hikmawati e.a., 2021).

Het proces start doorgaans met *data profiling* om problemen zichtbaar te maken, gevolgd door opschoning (cleaning) en synchronisatie. Deze stappen zijn pas effectief wanneer ze gekoppeld zijn aan meetbare kwaliteitsdoelen, zoals indicatoren voor de duplicatiegraad (Hikmawati e.a., 2021).

Voor IPCOM betekent dit dat de technische oplossing gepaard moet gaan met governance die lokale verantwoordelijkheid en centrale uniformiteit combineert. Door data ownership toe te wijzen, wordt datakwaliteit een bestuurbaar resultaat in plaats van een toevallige uitkomst (Vilminko-Heikkinen & Pekkola, 2019).

A.2.5. Bestaande MDM-oplossingen en implementatiebenaderingen

MDM-oplossingen variëren in architectuur, synchronisatiepatronen en governance-ondersteuning (Rengasamy, 2025). Vooral in multi-ERP-omgevingen is de keuze tussen centralisatie en federatie bepalend.

- **Gecentraliseerd:** Eén MDM-hub fungeert als de primaire bron.
- **Federated:** Eigenaarschap blijft bij businessfuncties, terwijl consistentie via afspraken wordt bewaakt. Dit is geschikt wanneer lokale autonomie zwaar weegt (Rengasamy, 2025).

Daarnaast onderscheidt de literatuur drie MDM-patronen (Rengasamy, 2025):

1. *Registry*: Focus op referenties en identifiers zonder dataverplaatsing.
2. *Coexistence*: Lokale opslag met synchronisatie naar een centrale standaard.
3. *Transaction Hub*: Real-time verwerking van updates als centrale autoriteit.

Voor multi-ERP-contexten worden vaak Coexistence of Transaction Hubs aangeraden, omdat bronsystemen operationeel moeten blijven (Maedche, 2010). Rengasamy (2025) adviseert een gefaseerde implementatie: starten met een afgebakend domein en iteratief uitbreiden. Dit sluit aan bij de visie dat datakwaliteit een continu proces is (Hikmawati e.a., 2021).

Voor IPCOM wordt een federated of coexistence-achtige benadering onderzocht. Dit maakt het mogelijk om centrale definities te combineren met operationele continuïteit in de ERP-systemen (Rengasamy, 2025).

A.2.6. Open uitdagingen en positionering van dit onderzoek

MDM-initiatieven kennen zowel technische als organisatorische uitdagingen (Pansara, 2021). Ten eerste is er **data governance**: zonder duidelijke rollen en procedures kunnen inconsistenties opnieuw in systemen sluipen (Pansara, 2021). De vraag is hoe governance consistentie kan afdwingen zonder lokale werking te blokkeren (Vilminko-Heikkinen & Pekkola, 2019).

Ten tweede vormt **data-integratie** een risico. Synchronisatieverschillen en semantische mismatches tussen MDM en ERP kunnen leiden tot fouten (Maedche, 2010). Ook bij het samenvoegen van records (survivorship) kan context verloren gaan (Pansara, 2021).

Ten derde vereisen **data-standaarden** afstemming tussen afdelingen, wat in gedecentraliseerde contexten moeilijk is.

Deze bachelorproef positioneert zich als toegepast onderzoek. MDM-concepten, matching-technieken en survivorship-strategieën worden vertaald naar een proof-of-concept voor de multi-ERP-casus van IPCOM. Het doel is om deze in-house oplossing in te zetten als een objectieve benchmark tegenover een commerciële MDM-pilot (Profisee). Hierbij wordt geëvalueerd hoe duplicatie effectief kan worden gereduceerd via deterministische en AI-gebaseerde matching, en of een in-house setup kwalitatief kan concurreren met een kant-en-klaar platform.

A.3. Methodologie

A.3.1. Onderzoekopzet

Deze bachelorproef is **toegepast onderzoek** binnen de bedrijfscontext van IPCOM en wordt uitgevoerd als **case study** met een **PoC** als technisch eindresultaat. De centrale onderzoeksvraag uit Sectie A.1 wordt beantwoord door (1) literatuurstudie, (2) requirements- en contextanalyse via directe afstemming met de interne data engineer, (3) ontwerp en implementatie van een PoC in Microsoft Fabric, waarbij de scope bewust beperkt wordt tot artikel- en leveranciersdata uit drie specifieke ERP-systemen (Oostenrijk, Zwitserland en Noorwegen). Tot slot volgt (4) een evaluatie waarbij deze in-house PoC fungeert als objectieve benchmark tegenover een lopende pilot met het commerciële MDM-platform Profisee.

A.3.2. Onderzoekstechnieken

De gebruikte onderzoekstechnieken zijn:

- **Literatuurstudie:** concepten, implementatiebenaderingen en open uitdagingen rond MDM, multi-ERP, golden records en datakwaliteit.
- **Expert-consultatie en documentanalyse:** directe afstemming met de co-promotor (data engineer) als hoofd-stakeholder en het hergebruiken van reeds intern opgestelde rule-sets en datamappings.
- **Data-analyse en data profiling:** bepalen van een objectieve baseline (zoals het huidige percentage ontbrekende velden) op representatieve datasets uit de geselecteerde bronsystemen.
- **Ontwerp en implementatie PoC:** data harmonisatie, deterministische en AI-gestuurde matching, survivorship rules en golden record-opbouw in Microsoft Fabric.

- **Evaluatie (Benchmark):** kwantitatieve en kwalitatieve vergelijking van de Fabric PoC-output met zowel de originele baseline als de resultaten van de Profisee-oplossing.

A.3.3. Dataverzameling en requirements

Er is directe toegang verleend tot de benodigde databases. Dit versnelt de dataverzameling aanzienlijk. De scope is afgebakend tot entiteiten van het type *Article* en *Supplier*, aangezien deze de grootste kans op overlap vertonen over de verschillende entiteiten heen. Klantendata wordt buiten beschouwing gelaten vanwege het sterk lokale karakter.

Er worden geen brede stakeholder-interviews gehouden; de requirements, pijnpunten en reeds bestaande mappings (bijvoorbeeld vertalingen van landcodes en lokale veldnamen) worden rechtstreeks gecapteerd via de interne data engineer. Dit vormt de fundering voor het canonical model.

A.3.4. Technische uitvoering van de PoC

De PoC implementeert een reproduceerbare pipeline in Microsoft Fabric met de volgende stappen:

1. **Landing:** inladen van datasnapshots uit de ERP-systemen van Zwitserland, Oostenrijk en Noorwegen.
2. **Harmonisatie:** toepassen van de bestaande mappings om data te vertalen naar één uniform canonical model.
3. **Matching:** groeperen van records. Dit verloopt in twee fasen om de benchmark te voeden:
 - *Deterministisch:* harde regels, zoals een match op basis van identieke EAN-codes in combinatie met hetzelfde leveranciers-ID.
 - *Fuzzy/AI-gebaseerd:* experimenteel matchen op artikelnamen als aanvulling, om te evalueren of dit superieure resultaten oplevert ten opzichte van de standaard logica.
4. **Survivorship:** toepassen van regels om het ultieme golden record te genereren, waarbij ook lokale referentie-ID's worden bijgehouden zodat bronsystemen via "foreign keys" kunnen terugverwijzen.
5. **Golden record store & Publicatie:** opslaan van de resultaten met uitgebreide auditvelden voor downstream consumptie in Power BI.

A.3.5. Evaluatiecriteria

De evaluatie gebeurt door een vergelijking op basis van meetbare indicatoren:

- **Benchmark Profisee:** presteert de opgezette logica in Fabric vergelijkbaar, beter of slechter dan de commerciële opzet wanneer dezelfde inputdata wordt gebruikt?
- **Impact op brondata:** hoe vaak en in welke mate wijzigt het gegenereerde golden record de originele data in een specifiek bronsysteem?
- **Volledigheid en Consistentie:** afname van het aantal ontbrekende waarden en conflicten tussen systemen voor dezelfde entiteit.
- **Traceerbaarheid:** transparantie in welke bronrecords en rules hebben geleid tot een specifieke golden record-waarde.

A.3.6. Tools en technologie (initiële keuze)

De architectuur leunt op het Microsoft-ecosysteem, met **Microsoft Fabric** (Lakehouse, Dataflows Gen2, Notebooks in Python/SQL) als integratieomgeving. **Power BI** wordt ingezet voor visuele validatie en het presenteren van de datakwaliteit en benchmark-metrieken.

A.3.7. Planning (14 weken, wekelijkse cyclus)

Door de interne toegang tot data en bestaande mappings kan de technische opstart versneld worden uitgevoerd.

A.4. Verwacht resultaat, conclusie

A.4.1. Verwachte resultaten

De verwachte uitkomst van deze bachelorproef is een technisch onderbouwde PoC voor Master Data Management (MDM) binnen Microsoft Fabric, die fungeert als objectieve benchmark tegenover de lopende Profisee-pilot bij IPCOM. Deze PoC levert een reproduceerbare pipeline op die (1) artikel- en leveranciersrecords uit Zwitserland, Oostenrijk en Noorwegen harmoniseert op basis van bestaande mappings, (2) records matcht via zowel deterministische regels als AI/fuzzy matching, (3) survivorship rules toepast om een golden record samen te stellen, en (4) de output publiceert voor consumptie en validatie in Power BI.

Op inhoudelijk niveau wordt verwacht dat de PoC een aantoonbare reductie van duplicatie en inconsistentie oplevert. Dit wordt geoperationaliseerd via een vergelijking tussen een baseline-meting en de PoC-output, maar bovenal door een vergelijking met de resultaten van de Profisee-setup op dezelfde dataset. Daarnaast wordt inzichtelijk gemaakt hoe vaak en in welke mate een golden record de originele waarden van een specifiek bronsysteem wijzigt.

A.4.2. Verwachte visualisaties en metingen

Om de resultaten objectief te evalueren en de benchmark visueel te ondersteunen, worden in Power BI minstens de volgende grafieken uitgewerkt:

- **Benchmark succesratio (Fabric vs. Profisee):** Een vergelijkende visualisatie die toont hoeveel unieke golden records (en correcte matches) beide systemen genereren op basis van dezelfde inputdata.
- **Impact op bronsystemen:** Een visualisatie die per bronsysteem (Zwitserland, Oostenrijk, Noorwegen) het percentage toont waarbij de uiteindelijke golden record-waarde afwijkt van de originele, lokale data. Dit beantwoordt direct de nieuwe onderzoeksvraag.
- **Duplicatiegraad per systeem (voor/na):** Staafdiagram met op de x-as de bronsystemen en op de y-as het percentage records dat als duplicaat wordt geïdentificeerd en geconsolideerd.
- **Volledigheid per attribuut (voor/na):** Staafdiagram met op de x-as kritieke attributen (bv. EAN, artikelnaam) en op de y-as het percentage ingevulde waarden. Verwacht wordt dat dit percentage stijgt doordat waarden over bronnen heen worden gecombineerd.
- **Traceerbaarheidsoverzicht:** Tabelvisualisatie waarin per golden record wordt getoond welke bronrecords zijn gematcht, inclusief referentie naar de lokale ID's, zodat bronsystemen deze "foreign keys" kunnen overnemen.

A.4.3. Meerwaarde voor de doelgroep

De doelgroep (met name de data engineers binnen IPCOM) verkrijgt met deze resultaten drie concrete voordelen. Ten eerste biedt de PoC een objectieve "Build vs. Buy"business case: het toont aan of een in-house oplossing in Fabric kan concurreren met de licentiekosten en complexiteit van Profisee. Ten tweede fungeren de doorontwikkelde mappings, rule-sets en analyses (zoals de AI-matching op artikelnaam) als direct bruikbare input, ongeacht welk platform uiteindelijk in productie gaat. Ten derde profiteren alle aangesloten entiteiten van de gerealiseerde golden records doordat lokale systemen eenduidig kunnen verwijzen naar verrijkte master data.

A.4.4. Verwachte conclusie

Op basis van de probleemsituatie bij IPCOM wordt verwacht dat de Fabric-PoC een aanzienlijke, meetbare verbetering oplevert in datakwaliteit binnen de multi-ERP-context. Specifiek wordt verwacht dat de toevoeging van AI of fuzzy matching op artikelnamen een significante meerwaarde biedt bovenop louter deterministische regels (zoals EAN-matches). De uiteindelijke conclusie zal uitwijzen of de in-house

ontwikkelde logica in Microsoft Fabric kwalitatief evenwaardig is aan de commerciële Profisee-pilot, en welke architectuur de meest schaalbare en kostenefficiënte route biedt voor de verdere uitrol binnen de IPCOM-groep.

Tabel A.1: Planning en deliverables (14 vrijdagen)

Week	Activiteit	Deliverable
1	Kick-off: scope-afbakening (Profisee benchmark) & ERP-selectie (CH, AT, NO)	Scope + afspraken gedocumenteerd
2	Data-extractie (Article/Supplier) + verzamelen bestaande mappings	Dataset snapshot + mappingdocument
3	Data landing in Fabric + eerste harmonisatie o.b.v. mapping	Werkende landing & harmonisatielaag
4	Data profiling + meten van baseline metrieken (bijv. % lege velden)	Baseline DQ-rapport
5	Ontwerp PoC-architectuur & voorbereiding rule-engine	Architectuurdiagram
6	Implementatie matching fase 1: deterministische rules (EAN/Supplier)	Werkende hard-rule set
7	Implementatie matching fase 2: Fuzzy matching / AI op Artikelnaam	AI-matching testresultaten
8	Implementatie survivorship rules & opbouw golden records	Golden record generator
9	Traceerbaarheid inbouwen (logging van gekozen bronwaarden)	Traceability-output + auditvelden
10	Evaluatie: analyse "Impact op brondata"(wijzigingsfrequentie)	Data-impact analyse
11	Vergelijking en benchmark resultaten tegenover de Profisee-oplossing	Benchmark-rapportage
12	Publicatie consumptielaag + Power BI validatie dashboards	Power BI proof + visualisaties
13	Stakeholder review met co-promotor (inzichten en werkbaarheid)	Reviewverslag
14	Finalisatie scriptie + formuleren advies (Fabric vs. Profisee)	Eindrapport + aanbevelingen

Bibliografie

- Elahi, E. (2024, juli). *Guide to data survivorship: How to build the golden record?* [Published July 26, 2024; last updated July 29, 2024]. Verkregen december 12, 2025, van <https://dataladder.com/guide-to-data-survivorship-how-to-build-the-golden-record/>
- Hikmawati, S., Santosa, P. I., & Hidayah, I. (2021). Improving Data Quality and Data Governance Using Master Data Management: A Review. *IJITEE*, 5(3), 90–95.
- Maedche, A. (2010). An ERP-centric Master Data Management Approach [Paper 384]. *Proceedings of the Americas Conference on Information Systems (AMCIS)*. <http://aisel.aisnet.org/amcis2010/384>
- Pansara, R. (2021). Master Data Management Challenges. *International Journal of Computer Science and Mobile Computing*, 10(10), 47–49. <https://doi.org/10.47760/ijcsmc.2021.v10i10.008>
- Rengasamy, A. (2025). AI Accelerator: Federated Master Data Management and Governance. *International Research Journal of Modernization in Engineering Technology and Science*, 7(2). <https://doi.org/10.56726/IRJMET567501>
- Vilminko-Heikkinen, R., & Pekkola, S. (2019). Changes in roles, responsibilities and ownership in organizing master data management. *International Journal of Information Management*, 47, 76–87. <https://doi.org/10.1016/j.ijinfomgt.2018.12.017>